


# Redes Neuronales

## Práctica 2

Clasificación de vino


## Alumna

M. en C. Diana Itzel Soto Castañeda

Facultad de Ciencias

Matrícula: 327690

## Profesores

Dr. Oscar Adrian Aguirre Castro

Dr. Everardo Inzunza Gonzales

Dr. Enrique Efrén García Guerrero


18 de octubre de 2026

# Resumen

La clasificación de la calidad del vino mediante técnicas de aprendizaje automático permite estudiar la relación entre sus propiedades fisicoquímicas y la evaluación sensorial realizada por catadores. El objetivo de esta práctica fue desarrollar y comparar modelos de clasificación capaces de identificar vinos de calidad alta a partir de sus características medibles, así como evaluar su capacidad de generalización.

Se utilizaron los conjuntos de datos *Wine Quality* del repositorio UCI, correspondientes a vinos tintos y blancos de la región portuguesa de Vinho Verde. Estos contienen 11 variables fisicoquímicas, entre ellas acidez, contenido de alcohol, densidad, cloruros y dióxido de azufre, además de una puntuación de calidad. El conjunto de vinos tintos comprende 1,599 registros, mientras que el de vinos blancos contiene 4,898. El procedimiento incluyó análisis exploratorio, revisión de valores faltantes y duplicados, preprocesamiento, división de los datos en entrenamiento y prueba, y evaluación mediante métricas de clasificación.

Se compararon tres algoritmos: máquinas de vectores de soporte (SVM), perceptrón multicapa (MLP) y bosque aleatorio (*Random Forest*). Asimismo, se emplearon validación cruzada estratificada y búsqueda de hiperparámetros para mejorar el desempeño. En los resultados registrados, el bosque aleatorio alcanzó una exactitud de 94.1 % en la comparación inicial de modelos para vinos tintos. Adicionalmente, una SVM optimizada obtuvo una exactitud de 90.9 % y un valor F1 de 0.659 en una evaluación posterior.

Los resultados muestran que la selección del modelo depende tanto de la exactitud global como de su capacidad para identificar correctamente los vinos de calidad alta. Se concluye que el aprendizaje automático permite analizar estos datos y construir clasificadores útiles, aunque el desbalance entre clases limita la detección de algunas categorías y debe considerarse al interpretar los resultados.

# 1. Introducción

La evaluación de la calidad del vino constituye un problema de interés para la industria vitivinícola, ya que permite relacionar las propiedades fisicoquímicas del producto con las valoraciones obtenidas mediante análisis sensoriales. Tradicionalmente, esta evaluación depende de la apreciación de expertos; sin embargo, los métodos de aprendizaje automático ofrecen una alternativa para identificar patrones en los datos y estimar la calidad a partir de mediciones objetivas. (Cortez et al., 2009) estudiaron el uso de técnicas de minería de datos para modelar las preferencias sobre vinos mediante variables fisicoquímicas, demostrando el potencial de estos métodos para apoyar los procesos de evaluación.

En esta práctica se utiliza el conjunto de datos *Wine Quality*, disponible en el repositorio UCI Machine Learning Repository, que contiene muestras de vinos tintos y blancos de la variedad portuguesa Vinho Verde. Las variables predictoras incluyen acidez fija y volátil, ácido cítrico, azúcar residual, cloruros, dióxido de azufre, densidad, pH, sulfatos y contenido de alcohol. La variable objetivo corresponde a una puntuación de calidad asignada mediante evaluación sensorial. El conjunto permite abordar problemas de clasificación o regresión; en este trabajo se plantea la clasificación de la calidad a partir de las características medidas (Cortez et al., 2009; Cortez, P. et al., 2009)

El problema presenta dificultades particulares debido a que las puntuaciones de calidad no se distribuyen uniformemente entre las clases. Esta situación puede provocar que un modelo clasifique correctamente las categorías más frecuentes, pero tenga un desempeño limitado en aquellas con menos observaciones. Por ello, la evaluación debe considerar métricas adicionales a la exactitud, como la precisión, la sensibilidad y la medida F1, que permiten analizar distintos aspectos del rendimiento de los clasificadores.

Para abordar el problema se comparan tres familias de algoritmos. La primera corresponde a las máquinas de vectores de soporte (*Support Vector Machines*, SVM), que buscan establecer fronteras de decisión capaces de separar las clases y pueden utilizar funciones kernel para representar relaciones no lineales (Cortes & Vapnik, 1995). La segunda comprende las redes neuronales de tipo perceptrón multicapa (*Multilayer Perceptron*, MLP), que aprenden representaciones y relaciones complejas mediante capas de neuronas artificiales y un proceso iterativo de optimización (Haykin & Haykin, 2009). La tercera familia está constituida por los bosques aleatorios (*Random Forest*), un método de aprendizaje por conjuntos que combina múltiples árboles de decisión para producir predicciones más robustas (Breiman, 2001).

El objetivo de la práctica es implementar, ajustar y comparar estos tres enfoques mediante herramientas de Scikit-learn, utilizando procedimientos de entrenamiento y evaluación que permitan estimar su capacidad de generalización. A partir de las métricas obtenidas, se busca determinar qué modelo ofrece el mejor equilibrio entre desempeño global y reconocimiento de las distintas clases de calidad, considerando las limitaciones asociadas al desbalance de los datos.

# 2. Materiales y métodos

## 2.1 Entorno de desarrollo y herramientas

La práctica se desarrolló en Jupyter Notebook integrado en Visual Studio Code (VS Code). Para ejecutar el código se utilizó un entorno virtual administrado mediante Conda, al cual se registró un kernel de Jupyter para seleccionar explícitamente el intérprete de Python correspondiente. Este procedimiento permitió trabajar desde VS Code con las bibliotecas instaladas en el entorno, ejecutar las celdas de forma interactiva y visualizar las tablas y gráficas generadas durante los experimentos.

El desarrollo se realizó con Python y la biblioteca Scikit-learn para implementar los clasificadores y evaluar su desempeño. Pandas se utilizó para cargar y manipular los datos, NumPy para operaciones numéricas y Matplotlib y Seaborn para la elaboración de gráficas. El cuaderno de referencia registra Python 3.12.15, Scikit-learn 1.9.1, Pandas 3.0.6, NumPy 2.5.3, Matplotlib 3.11.2 y Seaborn 0.13.2; estas versiones deben sustituirse por las obtenidas en el entorno local si difieren de las registradas en el cuaderno original.

## 2.2 Conjunto de datos y definición del problema

Se utilizó el conjunto de datos *Wine Quality* correspondiente al vino tinto, procedente del repositorio UCI Machine Learning Repository. El conjunto contiene 1,599 observaciones y 12 columnas: 11 variables predictoras fisicoquímicas y una variable objetivo denominada quality. Las variables de entrada incluyen acidez fija y volátil, ácido cítrico, azúcar residual, cloruros, dióxido de azufre libre y total, densidad, pH, sulfatos y contenido de alcohol.

El problema se formuló como una clasificación binaria mediante un umbral de calidad igual a 7. Las muestras con una puntuación de calidad mayor o igual que 7 se etiquetaron como vinos de calidad alta (clase 1), mientras que las muestras con puntuaciones inferiores a 7 se asignaron a la clase normal (clase 0). Esta transformación produjo 217 observaciones de calidad alta (13.6 %) y 1,382 de calidad normal (86.4 %), por lo que las clases presentan un desbalance importante.

Antes del entrenamiento se realizó un análisis exploratorio para revisar las dimensiones del conjunto, los tipos de datos, los valores faltantes, los registros duplicados y la distribución de la variable objetivo. En el conjunto original no se encontraron valores faltantes, pero se identificaron 240 filas duplicadas. Para el experimento principal se conservaron los registros tal como aparecen en el archivo original, con el propósito de mantener el protocolo de referencia; por tanto, los duplicados constituyen una limitación que se considera al interpretar los resultados.

## 2.3 Partición de los datos y escalado

Las 11 variables fisicoquímicas se utilizaron como matriz de entrada (X), mientras que la etiqueta binaria se definió como variable objetivo (y). Los datos se dividieron en un conjunto de entrenamiento del 80 % y un conjunto de prueba del 20 %, mediante train_test_split de Scikit-

learn. Se utilizó partición estratificada (stratify=y) para conservar aproximadamente la proporción de ambas clases en los dos subconjuntos y random_state=42 para hacer reproducible la partición. En la ejecución de referencia, el conjunto de prueba estuvo formado por 320 muestras.

Las variables predictoras se estandarizaron mediante StandardScaler, que transforma cada variable restando la media y dividiendo entre la desviación estándar calculadas en el conjunto de entrenamiento. Los parámetros obtenidos se aplicaron posteriormente al conjunto de prueba, sin volver a ajustarlos con sus datos. Este procedimiento evita utilizar información del conjunto de prueba durante el preprocesamiento y resulta especialmente relevante para SVM y MLP, cuyos resultados pueden verse afectados por las diferencias de escala entre variables.

## 2.4 Clasificadores e hiperparámetros

Se compararon tres clasificadores: máquinas de vectores de soporte, perceptrón multicapa y bosque aleatorio. Además, se utilizó un clasificador de referencia basado en la clase mayoritaria para valorar si los modelos aprendían a reconocer la clase minoritaria y no únicamente a predecir la categoría más frecuente.

La SVM se implementó con SVC (Support Vector Classifier), utilizando un kernel de base radial (kernel="rbf"), parámetro de regularización (C=1.0) y gamma="scale". El perceptrón multicapa se configuró mediante MLPClassifier, con dos capas ocultas de 64 y 32 neuronas (hidden_layer_sizes=(64, 32)), un máximo de 1,000 iteraciones y semilla 42. El bosque aleatorio se implementó con RandomForestClassifier, utilizando 200 árboles (n_estimators=200), semilla 42 y n_jobs=-1 para aprovechar los procesadores disponibles.

En una etapa adicional se ajustó la SVM mediante GridSearchCV. Se exploraron cuatro valores de (C) (0.1, 1, 10 y 100) y cuatro valores de gamma ("scale", 0.01, 0.1 y 1), para un total de 16 combinaciones. La selección se realizó maximizando la medida F1 mediante validación cruzada estratificada de cinco pliegues sobre el conjunto de entrenamiento. La estandarización se integró en un *pipeline* para ajustarla de nuevo dentro de cada pliegue y evitar la fuga de información. Esta búsqueda se consideró una etapa de optimización adicional, diferenciada de la comparación inicial con hiperparámetros de referencia.

## 2.5 Protocolo de validación y evaluación

La reproducibilidad se controló mediante la semilla 42, utilizada en la partición de los datos, en los clasificadores que admiten un estado aleatorio y en la generación de los pliegues de validación cruzada. La evaluación inicial se realizó sobre el conjunto de prueba reservado, que no intervino en el ajuste de los parámetros de los modelos.

Adicionalmente, se aplicó validación cruzada estratificada de cinco y diez pliegues (StratifiedKFold), con barajado de las observaciones y random_state=42. El procedimiento se ejecutó únicamente sobre el conjunto de entrenamiento. En cada pliegue, los modelos se

ajustaron con una parte de los datos y se evaluaron con la parte restante; el escalado se incorporó en un *pipeline* para que sus parámetros se calcularan exclusivamente a partir de los datos de entrenamiento de cada pliegue. Se calcularon la exactitud (*accuracy*) y la medida F1, y se reportaron sus medias y desviaciones estándar entre los pliegues.

La exactitud mide la proporción total de predicciones correctas, mientras que F1 combina precisión y sensibilidad mediante su media armónica. Dado que solo el 13.6 % de las muestras corresponde a la clase de calidad alta, ambas métricas se interpretaron conjuntamente para evitar que una exactitud elevada ocultara un reconocimiento deficiente de la clase minoritaria. Finalmente, la SVM optimizada se evaluó sobre el conjunto de prueba para obtener una estimación de su desempeño en datos no utilizados durante la selección de hiperparámetros.

# 3.Resultados.

En esta sección se presentan los resultados obtenidos durante el desarrollo de la práctica.

## 3.1 Análisis exploratorio de los datos del vino tinto.

El conjunto de datos de vino tinto estuvo compuesto por 1,599 registros y 12 columnas, correspondientes a 11 variables fisicoquímicas y una variable de calidad. No se encontraron valores faltantes y se identificaron 240 registros duplicados. Como se muestra en la Tabla A y la Figura 1, las puntuaciones de calidad se concentraron principalmente en las categorías 5 y 6, con 681 y 638 observaciones, respectivamente. En contraste, las categorías 3 y 8 presentaron las menores frecuencias, con 10 y 18 observaciones, respectivamente.

| Dato | Celda | Su valor |
|---|---|---|
| Filas × columnas | Paso 1 | 1599 x 12 |
| Valores faltantes · filas duplicadas | Paso 2 | Sin valores faltantes. Todas son variables tipo float, excepto por “quality” que es int |
| Vinos por nota de calidad (3 / 4 / 5 / 6 / 7 / 8) | Paso 3 | <table><tr><th>Calidad</th><th>Cantidad</th></tr><tr><td>3</td><td>10</td></tr><tr><td>4</td><td>53</td></tr><tr><td>5</td><td>681</td></tr><tr><td>6</td><td>638</td></tr><tr><td>7</td><td>199</td></tr><tr><td>8</td><td>18</td></tr></table> |
| Clase alta (≥ 7): vinos y % · clase normal: vinos y % · exactitud trivial | Paso 5 | Clase alta 13.6 %<br>Clase normal 86.4 %<br>Exactitud trivial 86.4 % |
| Entrenamiento: filas y % alta · Prueba: filas y % alta · % normal en prueba | Pasos 7 y 10 | Entrenamiento 1279 y 13.6 % de calidad alta<br>Prueba 320 y 13.4 % de calidad alta |

| Dato | Celda | Su valor |
|---|---|---|
| Filas de prueba con las 11 variables repetidas en entrenamiento | Paso 7 | 77 filas repetidas en la prueba que también están en el entrenamiento |

*Tabla A Datos del vino tinto.*

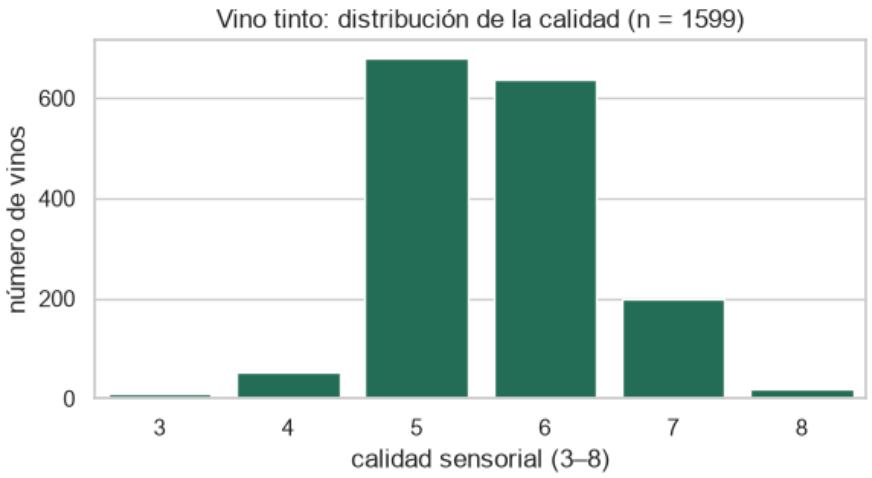



*Figura 1 Distribución de la calidad en Vino Tinto.*

En cuanto al análisis de correlación, el alcohol presentó la mayor asociación con la puntuación de calidad, seguido de la acidez volátil y los sulfatos, Tabla B. La Figura 2 muestra los diagramas de caja para el alcohol y la acidez volátil según la calidad del vino.

Asimismo, se registraron las estadísticas de las variables alcohol y acidez volátil antes y después de la estandarización. Estos resultados permitieron describir las relaciones entre las variables y documentar los cambios asociados al preprocesamiento.

| Dato | Celda | Su valor |
|---|---|---|
| Variable más correlacionada con la calidad (r) | Paso 4 | alcohol |
| Segunda (r) · Tercera (r) | Paso 4 | Acidez volátil<br>sulfatos |
| Su hipótesis: variable que el modelo usará más | Paso 4 | alcohol |
| Variable 1: media y desv. en entrenamiento, antes → después; media escalada en prueba | Paso 8 | Alcohol — media: 10.442, std — 1.077 → después media — -0.090 |
| Variable 2: media y desv. en entrenamiento, antes → después; media escalada en prueba | Paso 8 | Acidez volatile — media: 0.527 — std: 1.178 → después media — 0.035 |

*Tabla B Análisis exploratorio y escalado del vino tinto.*

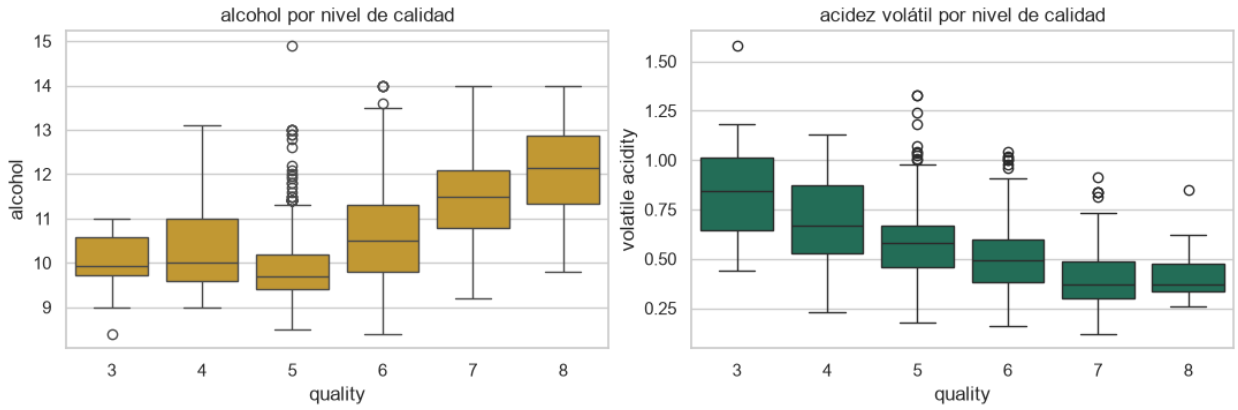



*Figura 2 Diagramas de caja del contenido de alcohol y la acidez volátil según la calidad del vino.*

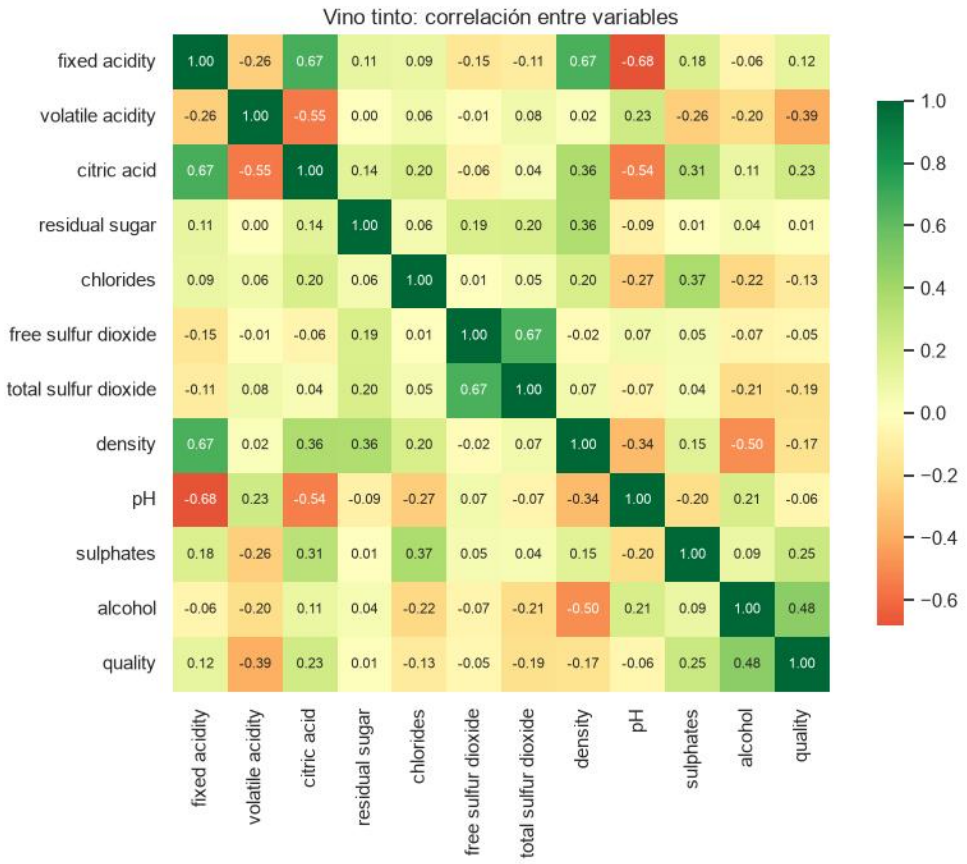



*Figura 3 Mapa de correlación entre variables del vino tinto.*

Para la clasificación binaria, se consideraron vinos de calidad alta aquellos con una puntuación mayor o igual que 7, mientras que las puntuaciones inferiores se clasificaron como calidad normal. La clase alta representó el 13.6 % de las observaciones, frente al 86.4 % de la clase normal. Esta distribución evidencia un desbalance entre las clases. Como referencia, la estrategia de predecir siempre la clase mayoritaria alcanzó una exactitud de 86.6 % en el conjunto de prueba como se muestra en los datos de Línea base de la Tabla C de la siguiente sección.

## 3.2 Comparación del desempeño de los clasificadores

La Figura 3 presenta el desempeño de los tres clasificadores sobre el conjunto de prueba. El bosque aleatorio obtuvo la mayor exactitud (0.941), seguido del perceptrón multicapa (0.925) y la máquina de vectores de soporte (0.900). Asimismo, Random Forest alcanzó los valores más altos de precisión (0.929), medida F1 (0.732) y área bajo la curva ROC (0.952).

Respecto a la identificación de los vinos de calidad alta, Random Forest y el perceptrón multicapa obtuvieron una sensibilidad de 0.605, superior a la registrada por la SVM de0.372. Esto indica que ambos modelos identificaron una mayor proporción de las muestras pertenecientes a la clase minoritaria. En conjunto, Random Forest presentó el mejor desempeño entre los modelos evaluados, al combinar la mayor exactitud con los mejores resultados en precisión, F1 y AUC.

La Figura 4 muestra las matrices de confusión de los tres modelos evaluados sobre el conjunto de prueba, lo que permite comparar la clasificación correcta e incorrecta de los vinos de calidad alta y normal. Se observa que el bosque aleatorio y el perceptrón multicapa identificaron correctamente 26 vinos de calidad alta cada uno, mientras que la SVM identificó 16. En cuanto a las predicciones incorrectas de vinos de calidad normal como alta, Random Forest presentó 2 falsos positivos, el MLP 7 y la SVM 5. Estos resultados muestran que Random Forest logró el mejor equilibrio entre la identificación de vinos de calidad alta y la reducción de falsos positivos.

| Modelo | VP · FP · FN · VN | Exact. | Ex. bal. | Prec. | Sens. | Espec. | F1 | MCC | AUC | t (s) |
|---|---|---|---|---|---|---|---|---|---|---|
| Línea base | 0·0·43·277 | 0.866 | 0.5 | 0.0 | 0.0 | 1.0 | 0.0 | 0.0 | 0.5 | 0.0 |
| SVM (RBF) | 16·5·27·272 | 0.9 | 0.677 | 0.762 | 0.372 | 0.982 | 0.5 | 0.488 | 0.889 | 0.016 |
| MLP (64, 32) · épocas: · convergió: | 26·7·17·270 | 0.925 | 0.79 | 0.788 | 0.605 | 0.975 | 0.684 | 0.65 | 0.882 | 1.402 |
| Random Forest (200) | 26·2·17·275 | 0.941 | 0.799 | 0.929 | 0.605 | 0.993 | 0.732 | 0.721 | 0.952 | 0.172 |

*Tabla C Desempeño sobre la prueba, vino tanto*

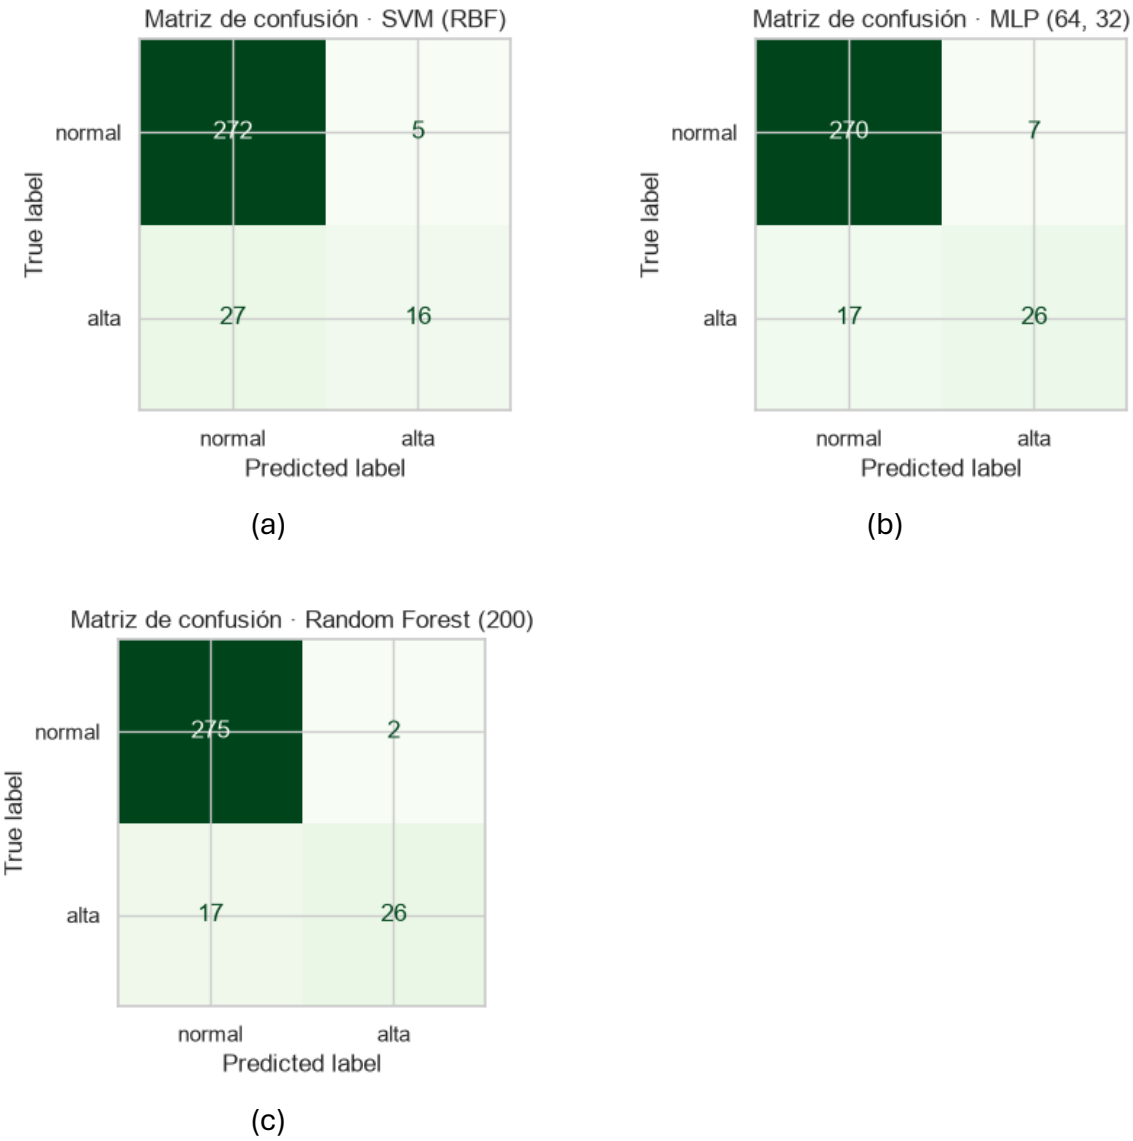



*Figura 4 Matrices de confusión de los tres modelos: (a) máquina de vectores de soporte (SVM), (b) perceptrón multicapa (MLP) y (c) bosque aleatorio (Random Forest).*

La Figura 5 muestra las curvas ROC de los tres clasificadores evaluados sobre el conjunto de prueba. El bosque aleatorio obtuvo el mayor valor de AUC (0.95), seguido de la SVM (0.89) y el perceptrón multicapa (0.88). La curva de Random Forest se mantuvo por encima de las correspondientes a los otros modelos durante gran parte del recorrido, lo que indica una mayor capacidad para distinguir entre vinos de calidad alta y normal. Por su parte, la SVM y el MLP presentaron valores de AUC similares. En conjunto, estos resultados muestran que Random Forest tuvo el mejor desempeño en términos de discriminación entre clases.

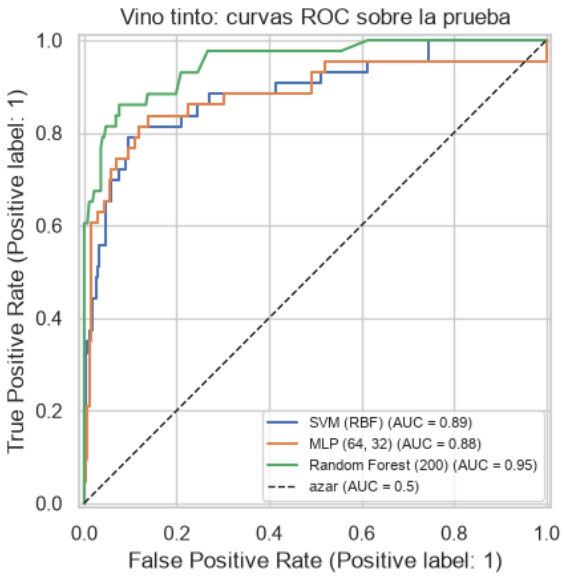



*Figura 5 Curva ROC sobre la prueba para vino tinto.*

La Tabla D muestra los resultados de la validación cruzada estratificada con cinco y diez pliegues sobre el conjunto de entrenamiento, mientras que la Figura 6 muestra la dispersión de los pliegues para cada uno de los modelos con cinco y diez pliegues. Con cinco pliegues, Random Forest obtuvo la mayor exactitud media (0.883), seguido de la SVM (0.880) y el perceptrón multicapa (0.873). Al utilizar diez pliegues, Random Forest mantuvo el mejor resultado, con una exactitud de 0.897, mientras que la SVM y el MLP alcanzaron valores de 0.880 y 0.879, respectivamente.

En cuanto a la medida F1, el perceptrón multicapa presentó un valor medio de 0.497 con cinco pliegues y de 0.527 con diez. Random Forest obtuvo valores de 0.460 y 0.521, respectivamente. Estos resultados muestran que, aunque Random Forest alcanzó la mayor exactitud media en ambas configuraciones, el MLP obtuvo un F1 ligeramente superior con cinco pliegues, mientras que las diferencias entre ambos modelos fueron pequeñas con diez pliegues.

| Modelo | Exactitud k = 5 | F1 k = 5 | Tiempo k = 5 (s) | Exactitud k = 10 | F1 k = 10 | Tiempo k = 10 (s) |
|---|---|---|---|---|---|---|
| SVM (RBF) | 0.880 ± 0.017 | 0.0364 ± 0.080 | 0.3 s | 0.880 ± 0.021 | 0.349 ± 0.125 | 0.4 s |
| MLP (64, 32) | 0.873 ± 0.025 | 0.497 ± 0.089 | 16.7 s | 0.879 ± 0.017 | 0.527 ± 0.077 | 30.6 s |
| Random Forest (200) | 0.883 ± 0.015 | 0.460 ± 0.079 | 1.7 s | 0.897 ± 0.026 | 0.521 ± 0.147 | 3.2 s |
| Duración de la celda completa (s) | 52.8 s | | | | | |

*Tabla D Validación cruzada sobre el entrenamiento, vino tinto (Fase 4). Media ± desviación.*

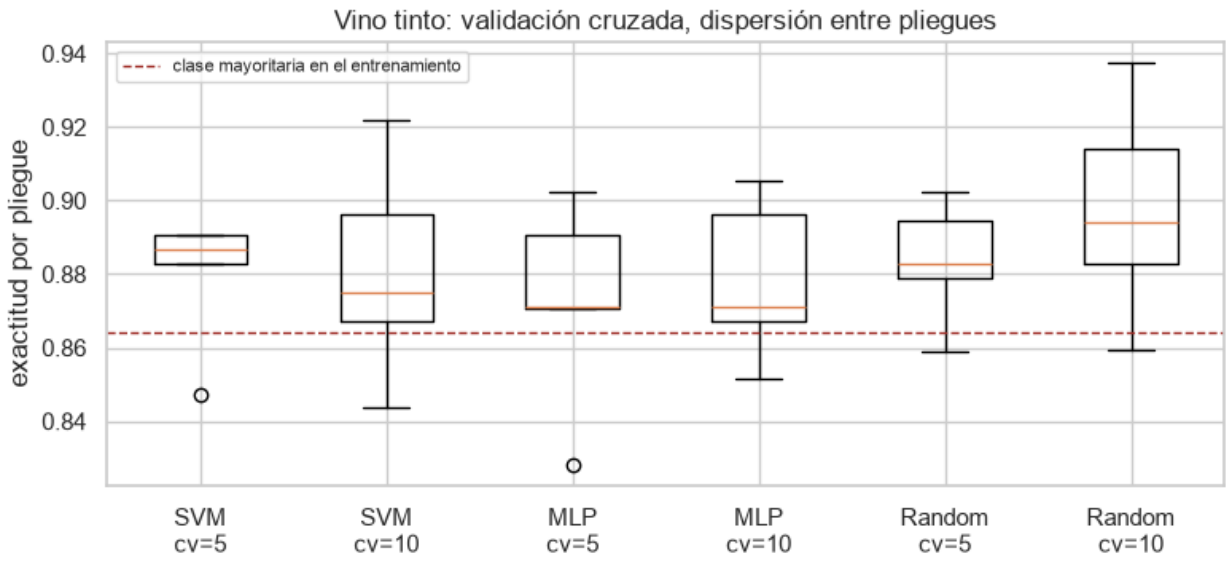



*Figura 6 Dispersión entre pliegues durante la validación cruzada del vino tinto para cada uno de los modelos.*

## 3.3 Vino blanco, análisis exploratorio de datos y desempeño de los clasificadores

El conjunto de datos de vino blanco estuvo compuesto por 4,898 registros y 12 columnas, todas numéricas, sin valores faltantes y con 937 registros duplicados. Como se muestra en la Tabla E y la Figura 6, las puntuaciones de calidad se concentraron principalmente en las categorías 6 y 5, con 2,198 y 1,457 observaciones, respectivamente. Las categorías menos frecuentes fueron 9, con 5 observaciones, y 3, con 20.

En el análisis de correlación, el alcohol presentó la mayor asociación con la puntuación de calidad ((r=0.436)), seguido de la densidad ((r=-0.307)) y los cloruros ((r=-0.210)). Estas asociaciones describen las relaciones lineales observadas entre las variables fisicoquímicas y la calidad del vino blanco.

Para la clasificación binaria, se estableció como calidad alta una puntuación mayor o igual que 7. Esta clase representó el 21.6 % de las muestras. La partición estratificada produjo 3,918 observaciones para entrenamiento y 980 para prueba. Además, se identificaron 292 registros del conjunto de prueba que también aparecían en el conjunto de entrenamiento.

| Dato | Su valor |
|---|---|
| Filas × columnas · columnas numéricas · faltantes · duplicados | 4898 x 12 · 12 ·0 · 937 |
| Vinos por nota de calidad (3 / 4 / 5 / 6 / 7 / 8 / 9) | 3: 20, 4: 163, 5: 1457, 6: 2198, 7: 880, 8: 175, 9: 5 |
| Clase alta (≥ 7): % · entrenamiento y prueba (filas) · filas de prueba repetidas en entrenamiento | calidad alta = 21.6 %, entrenamiento 3918, prueba 980, filas de prueba repetidas en entrenamiento 292 |
| Tres variables más correlacionadas con la calidad (r) | 'alcohol': 0.436, 'density': -0.307, 'chlorides': -0.21 |

*Tabla E Análisis exploratorio del vino blanco*

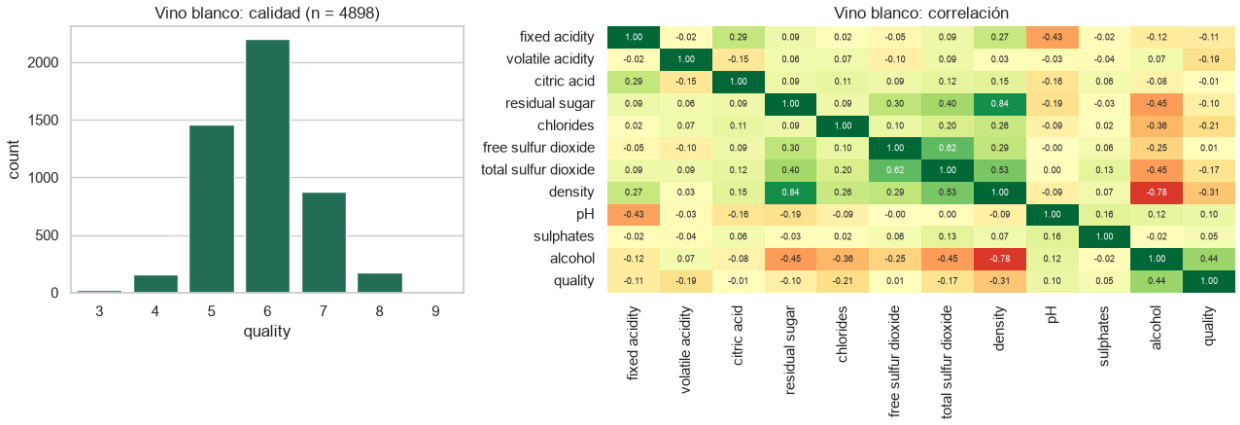



*Figura 7 Distribución de la Calidad del vino blanco y mapa de correlación de variables*

La Figura 7 presenta el desempeño de los tres clasificadores sobre el conjunto de prueba de vino blanco. Random Forest obtuvo la mayor exactitud (0.889), seguido del perceptrón multicapa (0.852) y la SVM (0.827). Asimismo, Random Forest alcanzó el mayor valor F1 (0.706) y el mayor AUC (0.928), mientras que el MLP obtuvo valores de 0.631 y 0.894, respectivamente. La SVM presentó el menor F1, con 0.444.

En la identificación de vinos de calidad alta, Random Forest obtuvo una sensibilidad de 0.618, seguido del MLP con 0.585 y la SVM con 0.321. En conjunto, estos resultados muestran que Random Forest presentó el mejor desempeño entre los modelos evaluados para el vino blanco. Sin embargo, su sensibilidad indica que todavía dejó sin identificar una proporción importante de las muestras de calidad alta.

| Modelo | VP · FP · FN · VN | Exact. | Prec. | Sens. | F1 | MCC | AUC | Exact. k = 5 | F1 k = 5 | Exact. k = 10 | F1 k = 10 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Línea base | 0·0·212·768 | 0.784 | | | | | 0.5 | — | — | — | — |
| SVM (RBF) | 68·26·144·742 | 0.827 | 0.723 | 0.321 | 0.444 | 0.401 | 0.857 | 0.823 ± 0.005 | 0.431 ± 0.019 | 0.825 ± 0.012 | 0.442 ± 0.038 |

| Modelo | VP · FP · FN · VN | Exact. | Prec. | Sens. | F1 | MCC | AUC | Exact. k = 5 | F1 k = 5 | Exact. k = 10 | F1 k = 10 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| MLP (64, 32) | 124·57·88·711 | 0.852 | 0.685 | 0.585 | 0.631 | 0.542 | 0.894 | 0.832 ± 0.009 | 0.605 ± 0.020 | 0.841 ± 0.022 | 0.624 ± 0.054 |
| Random Forest (200) | 131·28·81·740 | 0.889 | 0.824 | 0.618 | 0.706 | 0.649 | 0.928 | 0.870 ± 0.007 | 0.646 ± 0.020 | 0.873 ± 0.013 | 0.653 ± 0.037 |

*Tabla F Desempeño sobre la prueba y validación cruzada, vino blanco*

La Figura 8 muestra las matrices de confusión de los tres modelos evaluados sobre el conjunto de prueba de vino blanco. El bosque aleatorio identificó correctamente 131 vinos de calidad alta, seguido del perceptrón multicapa, con 124, y la SVM, con 68. En cuanto a los vinos de calidad alta que fueron clasificados incorrectamente como normales, el bosque aleatorio registró 81 falsos negativos, el MLP 88 y la SVM 144. Por otra parte, el número de falsos positivos fue de 28 para Random Forest, 57 para el MLP y 26 para la SVM. En conjunto, el bosque aleatorio identificó correctamente la mayor cantidad de vinos de calidad alta y presentó el menor número de falsos negativos, mientras que la SVM mostró mayores dificultades para reconocer esta clase.

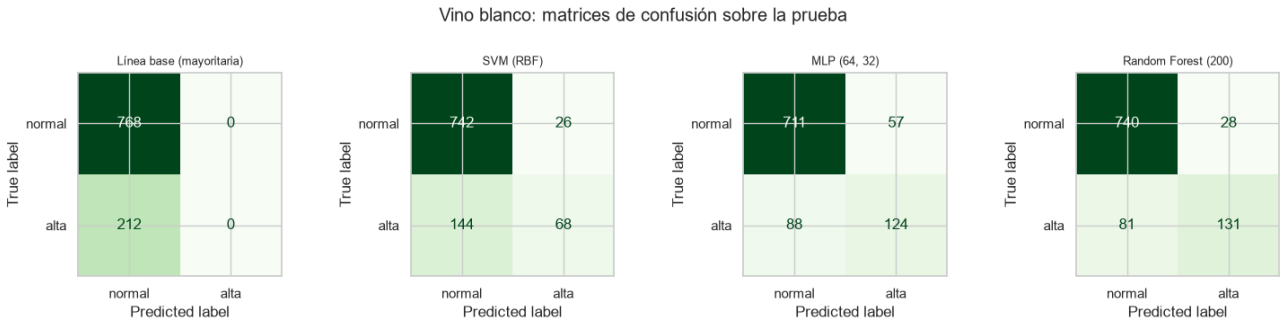



*Figura 8 Matrices de confusión de los tres modelos: (a) máquina de vectores de soporte (SVM), (b) perceptrón multicapa (MLP) y (c) bosque aleatorio (Random Forest) para el caso del Vino Blanco.*

La Figura 9 presenta las curvas ROC de los tres clasificadores sobre el conjunto de prueba de vino blanco. El bosque aleatorio obtuvo el mayor valor de AUC (0.928), seguido del perceptrón multicapa (0.894) y la SVM (0.857). La curva de Random Forest mostró la mayor capacidad de discriminación entre los vinos de calidad alta y normal, mientras que la SVM presentó el menor valor de AUC. Los tres modelos superaron la referencia de clasificación aleatoria (AUC = 0.5), aunque con diferencias en su capacidad para distinguir ambas clases. Estos resultados coinciden con las métricas de la Tabla F, en la que Random Forest también obtuvo la mayor exactitud y medida F1.

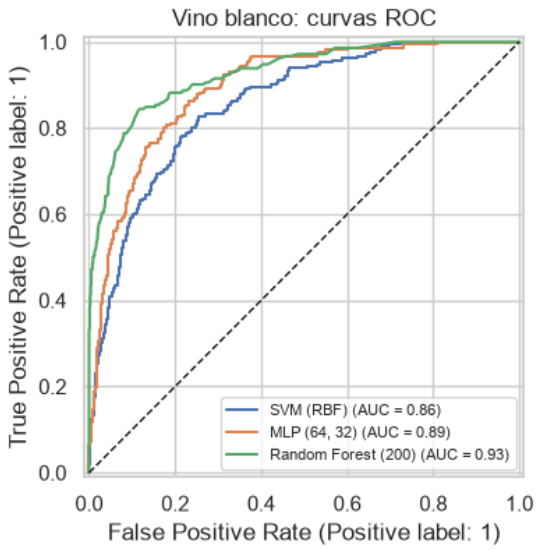



*Figura 9 Curva ROC sobre la prueba para vino blanco.*

## 3.4 Clasificación del vino tinto sin registros duplicados

En este experimento se evaluó el desempeño de los tres clasificadores después de eliminar los registros duplicados del conjunto de vino tinto. Como se muestra en la Tabla G, el bosque aleatorio obtuvo la mayor exactitud (0.893), seguido de la SVM (0.886) y el perceptrón multicapa (0.875). Sin embargo, el MLP alcanzó la mayor exactitud balanceada (0.711) y el mayor valor F1 (0.514), mientras que Random Forest obtuvo un F1 de 0.473 y la SVM de 0.436.

En la validación cruzada de cinco pliegues, el MLP también presentó el mayor F1 medio (0.448 ± 0.057), seguido de Random Forest (0.395 ± 0.069) y la SVM (0.302 ± 0.068). Estos resultados muestran que, aunque Random Forest obtuvo la mayor exactitud en el conjunto de prueba, el perceptrón multicapa presentó un mejor equilibrio en las métricas que consideran el desempeño sobre ambas clases.

En comparación con la evaluación inicial del vino tinto, los valores de exactitud y F1 fueron menores para los tres modelos en este experimento. No obstante, esta diferencia debe interpretarse considerando que la eliminación de duplicados también modificó el tamaño del conjunto de datos y la partición utilizada para la evaluación.

En el experimento de clasificación multiclase se utilizó Random Forest para predecir las puntuaciones de calidad del vino tinto entre las categorías 3 y 8. Como se muestra en laTabla G, el modelo obtuvo una exactitud de 0.675 y una exactitud balanceada de 0.385.

La diferencia entre ambas métricas indica que el desempeño no fue uniforme entre las categorías de calidad. Aunque el modelo clasificó correctamente una proporción considerable de las muestras en términos globales, la exactitud balanceada más baja refleja un reconocimiento desigual de las distintas clases. Este resultado debe interpretarse considerando que las puntuaciones de calidad presentan frecuencias muy diferentes en el conjunto de datos.

| Experimento | n (entren. / prueba) | Exactitud | Ex. balanceada | F1 | MCC | F1 k = 5 |
|---|---|---|---|---|---|---|
| Tinto sin duplicados · SVM | 1087/272 | 0.886 | 0.649 | 0.436 | 0.412 | 0.302 ± 0.068 |
| Tinto sin duplicados · MLP | 1087/272 | 0.875 | 0.711 | 0.514 | 0.444 | 0.448 ± 0.057 |
| Tinto sin duplicados · Random Forest | 1087/272 | 0.893 | 0.665 | 0.473 | 0.455 | 0.395 ± 0.069 |
| Tinto multiclase (3 a 8) · Random Forest | | 0.675 | 0.385 | — | — | — |

*Tabla G Duplicados y multiclase*

La Figura 10 correspondiente a las matrices de confusión permite comparar los aciertos y errores de los tres clasificadores después de eliminar los registros duplicados del conjunto de vino tinto, mientras que la Figura 11muestra la comparación de las curvas ROC para los tres modelos.

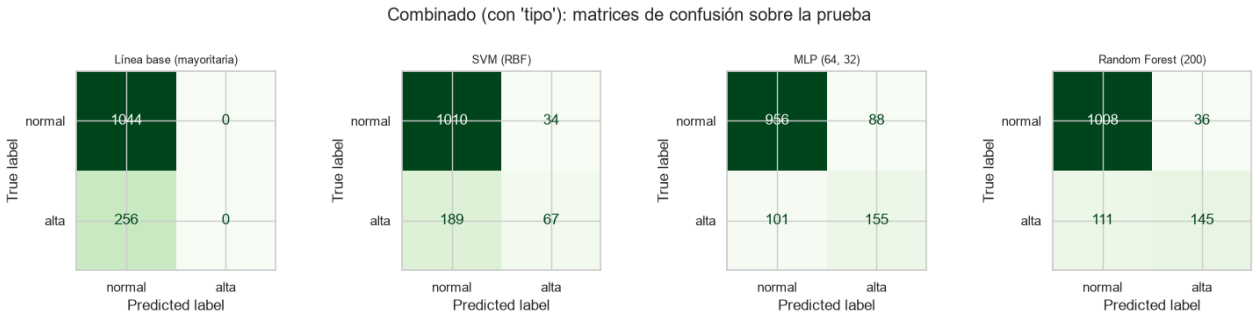



*Figura 10 Matrices de confusión de los tres modelos: (a) máquina de vectores de soporte (SVM), (b) perceptrón multicapa (MLP) y (c) bosque aleatorio (Random Forest) sin duplicados del entrenamiento en la prueba.*

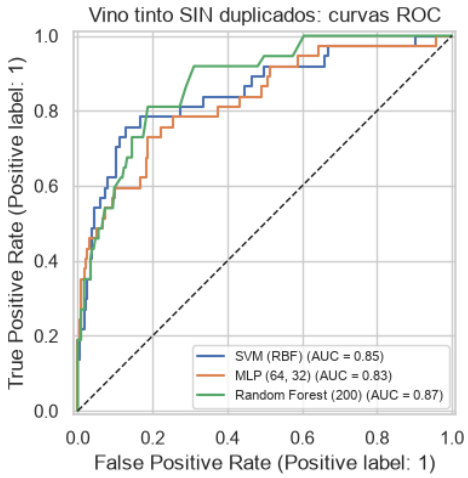



*Figura 11 Curva ROC sobre la prueba sin duplicados.*

## 3.5 Clasificación del vino considerando el conjunto combinado de vinos tintos y blancos

El conjunto combinado estuvo compuesto por 6,497 registros y 13 columnas, de los cuales el 75.4 % correspondió a vinos blancos (Tabla H). En la clasificación del tipo de vino, Random Forest obtuvo una exactitud de 0.9962 y un valor F1 de 0.9974, lo que indica una elevada capacidad para distinguir entre vinos tintos y blancos. Las variables más relevantes para esta distinción fueron el dióxido de azufre total, los cloruros y la acidez volátil.

En la clasificación binaria de la calidad, las muestras con puntuación mayor o igual que 7 representaron el 19.7 % del conjunto combinado. Random Forest obtuvo una exactitud de 0.887 y un valor F1 de 0.664. Posteriormente, se comparó el modelo con y sin la variable tipo, manteniendo la misma partición de entrenamiento y prueba. Ambas configuraciones alcanzaron una exactitud de 0.886, un F1 de 0.659 y un MCC de 0.607. En validación cruzada de cinco pliegues, el F1 medio fue de 0.645 ± 0.040 con la variable tipo y de 0.644 ± 0.034 sin ella.

La importancia asignada a la variable tipo fue de 0.003, ubicándose en la última posición entre las 12 variables predictoras. En esta evaluación, incluir dicha variable no produjo una mejora apreciable en las métricas registradas.

| Dato | Su valor |
|---|---|
| Filas del combinado · % de blancos | Combinado: (6497, 13) \| blancos: 75.4 % |

| Dato | Su valor |
|---|---|
| Tinto vs blanco: exactitud · F1 · tres variables que más separan | exactitud = 0.9962 F1 = 0.9974<br><br>Variables que más separan tinto de blanco: ['total sulfur dioxide', 'chlorides', 'volatile acidity'] |
| Calidad alta en el combinado (Tabla de `experimento_completo`): exactitud y F1 del Random Forest | exactitud = 0.887 F1 = 0.664 |
| RF con `tipo` vs sin `tipo`, misma partición: exactitud, F1 y MCC de cada uno | RF con 'tipo' (prueba, exploratorio) · exactitud 0.886 F1 0.659 MCC 0.607<br><br>RF sin 'tipo' (prueba, exploratorio) · exactitud 0.886 F1 0.659 MCC 0.607 |
| F1 en validación cruzada (k = 5) con `tipo` · sin `tipo` | F1 en validación cruzada (k=5) · con 'tipo' 0.645 ± 0.040 · sin 'tipo' 0.644 ± 0.034 |
| Importancia de `tipo` en el bosque con `tipo` · posición entre las 12 variables | Importancia de 'tipo' en ese bosque: 0.003 \| posición: 12 de 12 |

*Tabla H Resultados para el conjunto combinado*

## 3.6 Ajuste de hiperparámetros

En el ajuste de hiperparámetros (Tabla I), la SVM optimizada mediante GridSearchCV seleccionó (C=100) y (\gamma=0.1), con un F1 de validación cruzada de 0.545. En el conjunto de prueba obtuvo una exactitud de 0.909, un F1 de 0.659 y un MCC de 0.607. Estos resultados fueron inferiores a los de la SVM inicial, que alcanzó una exactitud de 0.941 y un F1 de 0.732.

También se evaluó la configuración del MLP presentada en el video, con tres capas ocultas de 11 neuronas y un máximo de 500 iteraciones. El modelo no convergió dentro de ese límite y obtuvo una exactitud de 0.903, un F1 de 0.575 y un MCC de 0.533. En conjunto, los resultados muestran que las configuraciones adicionales evaluadas no superaron el desempeño de la SVM inicial en el conjunto de prueba.

| Experimento | Parámetros | F1 en validación | Exactitud prueba | F1 prueba | MCC prueba |
|---|---|---|---|---|---|
| SVM por omisión (Tabla C) | C = 1, gamma = scale | 0.364 ± 0.080 | 0.941 | 0.732 | 0.721 |
| SVM con `GridSearchCV` | C =100 , gamma =0.1 | 0.545 | 0.909 | 0.659 | 0.607 |
| MLP del video (11, 11, 11), 500 it. · convergió: | iteraciones:500 sin convergencia | F1 k = 5: 0.492 ± 0.067 | 0.903 | 0.575 | 0.533 |

*Tabla I Ajuste de hiperparámetros de SVM y MLP.*

# 4.Conclusiones

En esta práctica se compararon máquinas de vectores de soporte (SVM), perceptrón multicapa (MLP) y bosque aleatorio (Random Forest) para clasificar vinos de calidad alta a partir de sus propiedades fisicoquímicas. En la comparación inicial, Random Forest obtuvo el mejor desempeño general en ambos conjuntos de datos: para vinos tintos alcanzó una exactitud de 0.941 y un F1 de 0.732, mientras que para vinos blancos obtuvo una exactitud de 0.889 y un F1 de 0.706.

El desbalance entre las clases influyó en la evaluación de los modelos, ya que los vinos de calidad alta representaron una proporción minoritaria de las muestras. Por ello, la exactitud no fue suficiente para valorar su desempeño. Métricas como F1 y sensibilidad permitieron evaluar con mayor precisión la capacidad de identificar vinos de calidad alta y evidenciaron diferencias entre los modelos, incluso cuando sus valores de exactitud eran similares.

También se examinó el efecto de los registros duplicados mediante una evaluación adicional del conjunto de vinos tintos sin duplicados. Los resultados cambiaron respecto a la evaluación inicial, lo que muestra la importancia de revisar la duplicidad de las observaciones antes de entrenar y evaluar los modelos. Sin embargo, dado que la composición y el tamaño del conjunto de datos también cambiaron, esta comparación no permite atribuir todas las diferencias de desempeño únicamente a la eliminación de duplicados.

Finalmente, el ajuste de hiperparámetros mediante GridSearchCV no mejoró el desempeño de la SVM respecto a su configuración inicial en el conjunto de prueba. Asimismo, el MLP con la arquitectura propuesta en el video no convergió dentro del límite de iteraciones establecido y obtuvo métricas inferiores a las de la SVM inicial y Random Forest. Estos resultados muestran que modificar la configuración de un modelo no garantiza una mejora y que es necesario evaluar los cambios mediante validación cruzada y datos de prueba independientes.

En conclusión, Random Forest fue la alternativa más efectiva entre los modelos comparados en la evaluación inicial. No obstante, la selección de un clasificador debe considerar tanto su exactitud como su capacidad para reconocer la clase minoritaria. El tratamiento de duplicados, el desbalance de clases y la validación de los modelos son aspectos fundamentales para interpretar los resultados y estimar su capacidad de generalización.

## 5. Uso de inteligencia artificial

Se utilizó ChatGPT (OpenAI), basado en el modelo GPT-6, como herramienta de apoyo para la redacción, organización y revisión de este reporte. Su uso se limitó a mejorar la claridad y coherencia del texto, resumir los resultados obtenidos y apoyar la interpretación de las métricas de evaluación de los modelos de clasificación.

Los datos, resultados numéricos, métricas y configuraciones de los modelos se verificaron con el código y las salidas del cuaderno de Jupyter utilizado para realizar la práctica. La herramienta de inteligencia artificial no sustituyó la ejecución del programa ni la comprobación de los resultados experimentales.

## Bibliografía


Breiman, L. (2001). Random Forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, *20*(3), 273–297. https://doi.org/10.1007/BF00994018

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, *47*(4), 547–553. https://doi.org/10.1016/j.dss.2009.05.016

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *Wine Quality [Dataset]* [Data set]. UCI Machine Learning Repository. https://doi.org/10.24432/C56S3T

Haykin, S. S., & Haykin, S. S. (2009). *Neural networks and learning machines* (3rd ed). Prentice Hall.